

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Optimización de la Precisión en Modelos Predictivos mediante el Uso de Gradient Boosting	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	3
1.3.	Metodología y Análisis de la Literatura	4

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Optimización de la Precisión en Modelos Predictivos mediante el Uso de Gradient Boosting

Autor: Mateo Fabián Silva Aguilar
Técnica asignada: Gradient Boosting

1.1. Introducción

Este capítulo aborda formalmente el uso de los algoritmos de aprendizaje supervisado basados en ensambles para dar respuesta a la pregunta de investigación planteada: ¿Cómo influye el uso de Gradient Boosting en la optimización de la precisión y la reducción del error en modelos predictivos complejos? A través del análisis de implementaciones avanzadas como XGBoost y LightGBM, se evalúa el impacto de esta técnica en entornos de alta dimensionalidad y su capacidad de generalización frente a modelos analíticos tradicionales [1–3].

La literatura científica reciente demuestra que la flexibilidad metodológica de estos algoritmos permite resolver problemas críticos que abarcan desde la predicción climática estacional [4] hasta la estimación de retrasos en proyectos de ingeniería de software mediante enfoques basados en reglas [5], consolidando al Gradient Boosting como una herramienta fundamental en la ciencia de datos contemporánea.

1.2. Fundamentos Teóricos

Gradient Boosting es una técnica de aprendizaje automático orientada a problemas de regresión y clasificación que construye un modelo predictivo de forma iterativa mediante un ensamble de estimadores débiles, típicamente árboles de decisión [6, 7]. A diferencia de los métodos de ensamble tradicionales basados en promedios simples o votaciones, este algoritmo optimiza una función de pérdida arbitraria calculando secuencialmente el gradiente descendente en el espacio de funciones [8].

Matemáticamente, el modelo final $F_M(x)$ se construye de forma aditiva. En cada iteración m , se entrena un estimador débil $h_m(x)$ para predecir los residuos (o gradientes negativos) de la función de pérdida con respecto al estado del modelo anterior, expresándose formalmente en la Ecuación 1.1:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x) \quad (1.1)$$

Donde γ_m representa la tasa de aprendizaje o tamaño del paso, un hiperparámetro crítico que a menudo se refina acoplando el algoritmo con optimización Bayesiana y arquitecturas robustas. Esto permite mitigar los efectos negativos de los datos ausentes o la alta volatilidad de los parámetros de entrada [9–11].

1.3. Metodología y Análisis de la Literatura

Mediante una rigurosa revisión de la literatura en bases de datos indexadas de alto impacto, se clasificaron las aplicaciones del Gradient Boosting (y en especial su variante Extreme Gradient Boosting, XGBoost) en diversas disciplinas. El espectro de estudio revela una adopción masiva en el área de la informática médica y el diagnóstico clínico, abarcando desde la evaluación de riesgos de accidentes cerebrovasculares [1, 12], complicaciones cardiovasculares en pacientes diabéticos [2, 13] y parámetros hemodinámicos en choque cardiogénico [14], hasta el pronóstico de recuperación funcional post-hemorragia [15] y la detección de hemorragias subaracnoideas aneurismáticas [16]. Asimismo, se constata su alta precisión en oncología pediátrica y mamaria [17, 18], la detección temprana de osteoporosis [19], la predicción de reacciones severas a la quimioterapia [20] y el control epidemiológico de bacterias resistentes en unidades de cuidados intensivos [21].

Por otro lado, la versatilidad del algoritmo se extiende a la ingeniería aplicada y las ciencias de la Tierra. En el ámbito energético y de materiales, se evidencia su efectividad en la predicción de bandas prohibidas de compuestos binarios [8], propiedades de aleaciones poliméricas [11] y la optimización del rendimiento en colectores solares térmicos de placa plana [22]. En geociencias e ingeniería petrolera, el modelado mediante Gradient Boosting permite estimar con precisión el contenido de carbono orgánico total en esquistos lacustres [10] y caracterizar yacimientos en campos petrolíferos marítimos [23]. Finalmente, en el sector agroforestal y ambiental, el algoritmo ha sido potenciado mediante optimización metaheurística híbrida para proyectar el rendimiento de cultivos de nogal [24], así como para mejorar las predicciones numéricas de visibilidad atmosférica [25].

Este mapeo exhaustivo de la literatura científica facilitó la estructuración de las dimensiones de rendimiento técnico explicadas en la Tabla 1.1.

Tabla 1.1: Dimensiones de análisis y métricas de rendimiento en Gradient Boosting.

Parámetro	Ventaja Tecnológica	Restricción
Cómputo	Regularización avanzada (ℓ_1 y ℓ_2) que evita el sobreajuste y arquitectura preparada para la paralelización en grandes volúmenes de datos [17, 23].	Elevado costo temporal y consumo de recursos durante las fases de ajuste de hiperparámetros complejos [9].
Precisión	Minimización robusta de residuos no lineales mediante aproximaciones de Taylor de segundo orden en la función de pérdida [24, 25].	Alta propensión al sobreajuste (overfitting) si la tasa de aprendizaje γ_m no está correctamente balanceada con el número de árboles [7].
Explicabilidad	Capacidad de integración nativa con metodologías agnósticas de atribución de características como SHAP, facilitando la auditoría del modelo [15, 17].	Comportamiento interno de tipo caja negra ("black-box"), lo que dificulta la trazabilidad analítica matemática directa de forma aislada [21].

Referencias

- [1] V. L. Ho, T. P. T. Le, and V. M. D. Nguyen, “LIGHTGBM-based machine learning model for stroke risk prediction,” *International Journal of Advances in Soft Computing and its Applications*, vol. 16, no. 1, pp. 186–196, 2024.
- [2] S. Soni, C. B. Moncy, A. Gupta, and V. Chandrakar, “Heart disease prediction system using machine learning algorithms and models: A comparative study of logistic regression, support vector machine, gradient boosting and decision trees,” in *AIP Conference Proceedings*, vol. 3386, p. 020081, 2026.
- [3] J. Moya-Carvajal, F. Tirado, X. A. López-Cortés, and A. M. Carvajal Silva, “Triage level prediction using machine learning with tree-based gradient boosting algorithms,” in *Proceedings - IEEE CHILEAN Conference on Electrical, Electronics Engineering, Information and Communication Technologies (ChileCon 2025)*, 2025.
- [4] V. S. Monego, J. A. Anochi, and H. F. de Campos Velho, “South america seasonal precipitation prediction by gradient-boosting machine-learning approach,” *Atmosphere*, vol. 13, no. 2, p. 243, 2022.
- [5] Z. Shen, X. Wang, Z. Zhang, and H. Kim, “Domain-aware machine learning for project delay prediction: A rule-constrained XGBoost framework,” in *2025 10th International Conference on Computer and Information Processing Technology (ISCIPT 2025)*, pp. 9–13, 2025.
- [6] B. Li, H. Duan, S. Wang, J. Wu, and Y. Li, “Gradient boosting machine learning model for defective endometrial receptivity prediction by macrophage-endometrium interaction modules,” *Frontiers in Immunology*, vol. 13, p. 842607, 2022.
- [7] A. J. Zeleke, P. Palumbo, P. Tubertini, R. Miglio, and L. Chiari, “Machine learning-based prediction of hospital prolonged length of stay admission at emergency department: a gradient boosting algorithm analysis,” *Frontiers in Artificial Intelligence*, vol. 6, p. 1179226, 2023.
- [8] M. A. Pamungkas, A. E. Rofiah, and A. Naba, “Bandgap prediction of binary compounds via a machine learning approach utilizing gradient boosting regression,” *Journal of Computational Electronics*, vol. 25, no. 3, p. 100, 2026.
- [9] X.-X. Liang *et al.*, “Machine learning-based sales prediction using bayesian optimized XGBoost algorithms,” *Frontiers in Artificial Intelligence and Applications*, vol. 387, pp. 248–268, 2024.
- [10] X. Liu, Z. Tian, and C. Chen, “Total organic carbon content prediction in lacustrine shale using extreme gradient boosting machine learning based on bayesian optimization,” *Geofluids*, vol. 2021, p. 6155663, 2021.
- [11] S. Zheng, J. Hu, and Z. Yao, “Machine learning-driven prediction of polypropylene alloy properties: A bayesian network–XGBoost framework robust to missing data,” *Journal of Polymer Science*, vol. 64, no. 3, pp. 702–714, 2026.

- [12] S. Nithyaselvakumari, “Machine learning-based predictive model for ischemic stroke risk assessment: A data-driven approach using XGBoost,” in *Proceedings of the 9th International Conference on Electronics, Communication and Aerospace Technology (ICECA 2025)*, pp. 1060–1065, 2025.
- [13] J. Lee *et al.*, “Prediction of cardiovascular complication in patients with newly diagnosed type 2 diabetes using an XGBoost/ GRU-ODE-Bayes-based machine-learning algorithm,” *Endocrinology and Metabolism*, vol. 39, no. 1, pp. 176–185, 2024.
- [14] J. You *et al.*, “PiCCO hemodynamic parameters in cardiogenic shock: prediction of LVEF, NT-proBNP and MACE based on XGBoost machine learning model,” *Frontiers in Medicine*, vol. 12, p. 1683425, 2025.
- [15] M. He *et al.*, “Machine learning-based prediction of 6-month functional recovery in hypertensive cerebral hemorrhage: insights from XGBoost and SHAP analysis,” *Frontiers in Neurology*, vol. 16, p. 1608341, 2025.
- [16] R. Wang, J. Zhang, B. Shan, M. He, and J. Xu, “XGBoost machine learning algorithm for prediction of outcome in aneurysmal subarachnoid hemorrhage,” *Neuropsychiatric Disease and Treatment*, vol. 18, pp. 659–667, 2022.
- [17] A. Redlich, E. Pfaehler, M. Kunstreich, M. Schmutz, C. Lapa, and M. Kuhlen, “Machine learning prediction of recurrence in pediatric thyroid cancer: Malignant endocrine tumors cohort analysis using XGBoost and SHAP,” *Journal of Clinical Endocrinology and Metabolism*, vol. 111, no. 3, pp. e844–e852, 2026.
- [18] B. Likitha, J. Nakka, J. Verma, and N. S. Naik, “Prediction of breast cancer analysis using machine learning algorithms and XGBoost technique,” *Communications in Computer and Information Science*, vol. 1483, pp. 298–313, 2021.
- [19] G. Pandiya Rajan, K. Ganesan, B. Sivakarthick, K. Vignesh, and S. Naveen Prasath, “Osteoporosis prediction using machine learning: An XGBoost approach for early detection,” in *Proceedings of 2025 2nd International Conference on Cognitive Robotics and Intelligent Systems (ICC - ROBINS 2025)*, pp. 664–670, 2025.
- [20] M. Kathiravan, “Enhanced prediction of severe chemotherapy reactions through comparative analysis of XGBoost and classical machine learning models,” in *2025 10th International Conference on Applying New Technology in Green Buildings (ATiGB 2025)*, pp. 923–928, 2025.
- [21] Q. Pan, X. Zhou, B. Zhang, J. Li, Z. Wang, and Y. Guo, “Interpretable machine learning for early detection of carbapenem-resistant *Klebsiella pneumoniae* in ICUs: risk prediction using LASSO and XGBoost,” *Frontiers in Public Health*, vol. 14, p. 1798927, 2026.
- [22] M. Sridharan, “Performance augmentation study on a solar flat plate water collector system with modified absorber flow design and its performance prediction using the XGBoost algorithm,” *Iranian Journal of Science and Technology - Transactions of Mechanical Engineering*, vol. 48, no. 1, pp. 133–144, 2024.
- [23] L.-L. Dan, C.-L. Shi, J. Zhang, L. Wei, and L.-N. Yang, “Application of Xgboost algorithm based on machine learning in reservoir prediction of offshore oilfield,” *Springer Series in Geomechanics and Geoengineering*, pp. 3157–3167, 2021.
- [24] X. Guo, “Hybrid machine learning and metaheuristic optimization for hickory yield prediction: An empirical evaluation of SVR, XGBoost, and RF with AEO and ArchOA,” *Informatica (Slovenia)*, vol. 49, no. 26, pp. 1–22, 2025.

- [25] C. Han *et al.*, “A gradient boosting-based machine learning framework for improving atmospheric visibility numerical prediction,” *Atmospheric Research*, vol. 338, p. 109012, 2026.