

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
9.	Optimización de la Precisión mediante Gradient Boosting	2
9.1.	Introducción	2
9.2.	Fundamentos Teóricos Avanzados	3
9.2.1.	Estructura Algorítmica Formal del Modelo	4
9.2.2.	Optimización Numérica de Segundo Orden en Implementaciones Modernas	4
9.2.3.	Deducción de Gradientes para Funciones de Pérdida Especializadas	5
9.3.	Análisis de la Complejidad Computacional	6
9.4.	Diagnóstico de Convergencia y Parada Temprana (<i>Early Stopping</i>)	6
9.5.	Interpretabilidad y Atribución Multivariable de Características	7
9.5.1.	Importancia de Características por Ganancia de Entropía	7
9.5.2.	Valores Shapley Aditivos (SHAP)	8
9.6.	Metodología y Análisis de la Literatura	8
9.6.1.	Análisis de Sensibilidad de Hiperparámetros	8
9.6.2.	Estrategia de Optimización Fina de Hiperparámetros	8
9.6.3.	Métricas Estadísticas de Medición de la Precisión	9
9.6.4.	Comparativa de Infraestructura de Software y Requisitos de Hardware	9
9.7.	Conclusión del Capítulo	9

Parte I

Introducción y Fundamentos

Capítulo 9

Optimización de la Precisión en Modelos Predictivos mediante el Uso de Gradient Boosting

Autor: Mateo Fabián Silva Aguilar
Técnica asignada: Gradient Boosting

9.1. Introducción

Este capítulo aborda de manera exhaustiva el uso y la formalización de las técnicas de Gradient Boosting (GB) para estructurar una respuesta teórico-práctica a la pregunta de investigación central: ¿Cómo mejora Gradient Boosting la precisión en modelos predictivos? El Gradient Boosting representa un paradigma fundamental de aprendizaje supervisado dentro de la ciencia de datos moderna y la ingeniería de software predictivo, debido a su excepcional eficiencia en el análisis y modelado estadístico de estructuras de datos tabulares heterogéneos.

Desde su formulación teórica original como una aproximación numérica en el espacio de funciones abstractas empleando descenso de gradiente, esta metodología ha demostrado un desempeño sobresaliente en escenarios de alta complejidad algorítmica. Dichos entornos suelen caracterizarse por una alta dispersión de los datos, variables categóricas nominales de elevada cardinalidad, presencia endémica de ruido estocástico y registros faltantes o nulos. En estos contextos empíricos, los ensambles basados en boosting superan de forma sistemática a los modelos lineales tradicionales, a las metodologías multivariadas clásicas y a ciertas arquitecturas de redes neuronales profundas que requieren un volumen excesivo de hiperparametrización [1].

A diferencia de los métodos de agregación paralela o *bagging* —cuyo principal exponente es el algoritmo clásico *Random Forest*—, los cuales mitigan la varianza global del sistema mediante el entrenamiento simultáneo de múltiples árboles de decisión independientes construidos sobre submuestras aleatorias por reemplazo (*bootstrap samples*), el Gradient Boosting opera bajo una lógica estrictamente secuencial y aditiva. Este enfoque conceptual alternativo permite reducir de manera coordinada tanto el sesgo como la varianza residual del modelo predictivo a través de la inyección iterativa de funciones base parametrizadas de baja complejidad computacional. Su versatilidad operativa es tal que viabiliza el diseño y despliegue de plataformas complejas de monitoreo inteligente en infraestructuras industriales de alta disponibilidad [2].

Bajo este esquema aditivo, el algoritmo no busca ajustar un estimador complejo o de gran profundidad en una única iteración de cómputo. En su lugar, edifica un ensamble robusto de árboles de decisión donde cada nuevo submodelo o aprendiz débil (*weak learner*) se entrena con el propósito exclusivo de corregir los errores residuales, las variaciones no explicadas y las

desviaciones numéricas acumuladas por los árboles que le precedieron en el flujo del cómputo. Esta propiedad de aprendizaje adaptativo secuencial permite capturar interacciones no lineales de alto orden y estructuras latentes en datos multidimensionales que otros algoritmos omiten o interpretan erróneamente como ruido estadístico.

La relevancia de esta técnica se constata ampliamente en su adopción dentro de la literatura científica indexada a nivel global. Sus áreas de aplicación práctica se extienden desde el análisis predictivo de series temporales de tráfico destinadas a optimizar la movilidad y los tiempos de viaje en redes logísticas complejas [3], hasta la evaluación comparativa profunda entre arquitecturas avanzadas como XGBoost, CatBoost y LightGBM para determinar la eficiencia computacional interna en big data [4]. Por lo tanto, la comprensión rigurosa de sus fundamentos matemáticos, sus dinámicas de convergencia y sus determinantes operacionales es un requisito clave para el desarrollo contemporáneo de software predictivo de alta fidelidad.

9.2. Fundamentos Teóricos Avanzados

El principio fundamental del Gradient Boosting consiste en calcular la aproximación analítica de una función multivariable $F(x)$ mediante la combinación lineal y la optimización secuencial de un conjunto de funciones base parametrizadas $h(x; \theta)$ (generalmente árboles de regresión de profundidad fija o *stumps*), minimizando el valor esperado de una función de pérdida de datos arbitraria que sea estrictamente diferenciable en todo su dominio analítico, denotada formalmente como $L(y, F(x))$.

Dado un conjunto de entrenamiento finito compuesto por N instancias empíricas etiquetadas de la forma $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$, el algoritmo inicia inicializando el modelo predictivo global con una aproximación constante idónea $F_0(x)$. Este valor inicial representa el estimador óptimo base que minimiza la suma neta de la pérdida en el espacio euclidiano, tal como se expresa en la Ecuación 9.1:

$$F_0(x) = \arg \min_{\gamma} \sum_{i=1}^N L(y_i, \gamma) \quad (9.1)$$

Posteriormente, el proceso aditivo se ejecuta de forma iterativa a lo largo de un número predeterminado de M iteraciones secuenciales. El flujo algorítmico se compone de los siguientes pasos:

1. **Cálculo de componentes de gradiente:** Para cada etapa analítica definida por la iteración m (donde $m = 1, 2, \dots, M$), el algoritmo calcula los denominados pseudo-residuales para cada observación de entrada i . Estos pseudo-residuales, denotados matemáticamente como r_{im} , se derivan analíticamente calculando el valor del gradiente negativo de la función de pérdida específica evaluada con respecto a las predicciones generadas por la estructura del modelo en el paso inmediatamente anterior $F_{m-1}(x_i)$, de acuerdo con la formulación diferencial de la Ecuación 9.2:

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)} \quad \text{para } i = 1, \dots, N. \quad (9.2)$$

2. **Ajuste del aprendiz débil:** Una vez determinada la dirección de máximo descenso en el espacio funcional de la pérdida mediante los gradientes, se procede a ajustar un aprendiz débil $h_m(x)$ utilizando los pseudo-residuales r_{im} calculados como la variable objetivo temporal del sistema optimizador. El árbol resultante intenta aproximar la geometría de los residuos mapeando las regiones de mayor error.

3. **Optimización del tamaño de paso:** Logrado este ajuste del árbol de regresión residual, se calcula el tamaño de paso óptimo, multiplicador o parámetro de expansión ρ_m . Este procedimiento de sintonización lineal se lleva a cabo mediante una resolución de optimización unidimensional explícita descrita matemáticamente en la Ecuación 9.3:

$$\rho_m = \arg \min_{\rho} \sum_{i=1}^N L(y_i, F_{m-1}(x_i) + \rho h_m(x_i)) \quad (9.3)$$

4. **Actualización aditiva regularizada:** Finalmente, la evolución del modelo en la iteración m se consolida e integra de forma estrictamente aditiva al estado predictivo global. Con el propósito de mitigar los efectos del sobreajuste y la memorización de patrones espurios, se introduce un coeficiente de regularización denominado tasa de aprendizaje o *shrinkage* ($\eta \in (0, 1]$), que escala y atenúa la contribución del nuevo árbol estructurado, expresándose formalmente en la Ecuación 9.4:

$$F_m(x) = F_{m-1}(x) + \eta \cdot \rho_m h_m(x) \quad (9.4)$$

Donde de manera detallada se identifica que $h_m(x)$ es la función del aprendiz débil entrenado de forma complementaria para predecir los pseudo-residuales del modelo base previo $F_{m-1}(x)$; ρ_m es el coeficiente escalar de paso optimizado para minimizar el riesgo empírico remanente; y η actúa como el factor de atenuación que ralentiza el aprendizaje, obligando a los árboles sucesivos a buscar patrones complementarios con mayor capacidad de generalización.

9.2.1. Estructura Algorítmica Formal del Modelo

Para complementar el flujo matemático descrito previamente, a continuación se detalla la lógica procedural del Gradient Boosting en su formato computacional iterativo. Este diseño es fundamental para la correcta traslación teórica hacia entornos de programación basados en lenguajes de alto nivel.

Algoritmo Genérico de Gradient Boosting Linear Aditivo. [1] Conjunto de datos $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$, Función de pérdida $L(y, F(x))$, Número de iteraciones M , Tasa de aprendizaje η . Modelo de ensamble final optimizado $F_M(x)$. Inicializar $F_0(x) \leftarrow \arg \min_{\gamma} \sum_{i=1}^N L(y_i, \gamma)$ $m = 1$ M $i = 1$ N Calcular el pseudo-residual correspondiente:

$r_{im} \leftarrow - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)}$ Ajustar un aprendiz débil (árbol de regresión) $h_m(x)$ sobre

los objetivos temporales r_{im} . Calcular el tamaño de paso óptimo mediante optimización lineal:

$\rho_m \leftarrow \arg \min_{\rho} \sum_{i=1}^N L(y_i, F_{m-1}(x_i) + \rho h_m(x_i))$ Actualizar la composición del ensamble global con el factor de atenuación

$F_m(x) \leftarrow F_{m-1}(x) + \eta \cdot \rho_m h_m(x)$ $F_M(x)$

9.2.2. Optimización Numérica de Segundo Orden en Implementaciones Modernas

Las implementaciones computacionales contemporáneas han refinado este andamiaje matemático básico con el fin de proporcionar mejoras algorítmicas críticas indispensables para la computación a gran escala. La arquitectura de *Extreme Gradient Boosting* (XGBoost) implementa de forma nativa una expansión de la serie de Taylor de segundo orden directamente sobre la función objetivo de pérdida regularizada en la iteración m , expresada en la Ecuación 9.5:

$$\mathcal{L}^{(m)} \approx \sum_{i=1}^n \left[L(y_i, F_{m-1}(x_i)) + g_i h_m(x_i) + \frac{1}{2} j_i h_m^2(x_i) \right] + \Omega(h_m) \quad (9.5)$$

Donde g_i representa el gradiente de primer orden y j_i corresponde al término del Hessiano de segundo orden (la curvatura local de la pérdida), definidos analíticamente en las Ecuaciones 9.6:

$$g_i = \frac{\partial L(y_i, F_{m-1}(x_i))}{\partial F_{m-1}(x_i)} \quad y \quad j_i = \frac{\partial^2 L(y_i, F_{m-1}(x_i))}{\partial F_{m-1}^2(x_i)} \quad (9.6)$$

Esta formulación incorpora de manera directa la curvatura del error, posibilitando una convergencia e inferencia numérica sustancialmente más veloz y precisa que los métodos tradicionales de primer orden. Esta robustez matemática permite modelar desde dinámicas de rendimiento deportivo y factores de victoria bajo árboles de decisión aditivos [5], hasta resolver problemas de optimización estructural sobre estimaciones complejas de regresión continua [6].

Adicionalmente, el término de penalización estructural $\Omega(h_m)$ controla de forma explícita la complejidad geométrica del árbol aditivo según los pesos e hiperparámetros de regularización descritos en la Ecuación 9.7:

$$\Omega(h_m) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (9.7)$$

Donde T representa el número neto de hojas presentes en la topología del submodelo y w_j define el valor asignado a la predicción analítica de la j -ésima hoja. El acoplamiento de estas salvaguardas estructurales dota al Gradient Boosting de capacidades analíticas avanzadas, permitiendo estructurar esquemas explicables de ciberseguridad para la detección transparente de software malicioso o *PDFMal* sin sacrificar la interpretabilidad nodal del sistema [7].

Asimismo, estas optimizaciones posibilitan la transición desde proyecciones tradicionales puntuales hacia modelos de boosting probabilístico adaptados para la estimación de la frecuencia y severidad de siniestros en entornos actuariales altamente exigentes [8].

9.2.3. Deducción de Gradientes para Funciones de Pérdida Especializadas

La versatilidad del Gradient Boosting radica en que el cálculo explícito de los pseudo-residuales r_{im} varía en función de la topología estadística y la naturaleza del error matemático que se pretenda optimizar. En problemas de regresión predictiva continua robusta ante la presencia de observaciones atípicas, se implementa con frecuencia la función de pérdida por Error Cuadrático Medio ($L2$), cuya definición formal y derivación exacta de su gradiente se exponen analíticamente en las Ecuaciones 9.8 y 9.9:

$$L_{L2}(y_i, F(x_i)) = \frac{1}{2} (y_i - F(x_i))^2 \quad (9.8)$$

$$r_{im} = - \left[\frac{\partial L_{L2}(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)} = y_i - F_{m-1}(x_i) \quad (9.9)$$

Para escenarios de regresión expuestos a perturbaciones no gaussianas extremas o ruidosas, se recurre a la pérdida de Huber, la cual actúa de forma diferenciable combinando las propiedades de convergencia de $L2$ y la robustez contra anomalías de $L1$, parametrizada según la constante umbral δ en la Ecuación 9.10:

$$L_{\text{Huber}}(y_i, F(x_i)) = \begin{cases} \frac{1}{2} (y_i - F(x_i))^2 & \text{si } |y_i - F(x_i)| \leq \delta \\ \delta (|y_i - F(x_i)| - \frac{1}{2} \delta) & \text{si } |y_i - F(x_i)| > \delta \end{cases} \quad (9.10)$$

Por el contrario, para escenarios analíticos orientados a la clasificación binaria supervisada o la estimación de riesgos probabilísticos, el sistema requiere la parametrización de una función de pérdida fundamentada en la entropía cruzada binaria o *Log-Loss*. Asumiendo que el conjunto

de etiquetas binarias reales está restringido al espacio binario discreto $y_i \in \{0, 1\}$, la formulación analítica de la pérdida y la subsiguiente deducción diferencial de sus pseudo-residuales se detallan formalmente en las Ecuaciones 9.11 y 9.12:

$$L_{\text{Log}}(y_i, F(x_i)) = -y_i \log(p_i) - (1 - y_i) \log(1 - p_i) \quad (9.11)$$

$$p_i = \frac{1}{1 + e^{-F(x_i)}} \implies r_{im} = - \left[\frac{\partial L_{\text{Log}}}{\partial F} \right]_{F_{m-1}} = y_i - p_i = y_i - \frac{1}{1 + e^{-F_{m-1}(x_i)}} \quad (9.12)$$

9.3. Análisis de la Complejidad Computacional

El estudio del rendimiento técnico profundo del Gradient Boosting requiere una evaluación rigurosa de sus demandas algorítmicas en términos de espacio en memoria RAM y tiempo de ejecución en procesadores centrales. La construcción secuencial de múltiples árboles de decisión introduce retos que varían sustancialmente según las variantes de software implementadas y el tipo de modelado estadístico subyacente.

Cuando se trabaja con datos longitudinales de alta dimensionalidad, por ejemplo, las extensiones mixtas aditivas introducen penalizaciones específicas que modifican los costos asintóticos del cómputo estructural [9]. Para un dataset compuesto por N registros y K variables independientes (características), el costo computacional bruto de construir un árbol de decisión base convencional de profundidad máxima d escala analíticamente como $O(K \cdot N \cdot d \log N)$. Esto se debe a la necesidad intrínseca de ordenar continuamente los datos numéricos continuos en cada nodo divisor para evaluar los puntos de corte óptimos. Multiplicado por el número neto de árboles aditivos M , la complejidad de entrenamiento temporal agregada del sistema se establece bajo la expresión formal $O(M \cdot K \cdot N \cdot d \log N)$.

Estas demandas estructurales son especialmente críticas cuando se estiman modelos de regresión aplicados a la ingeniería prefabricada o el análisis del comportamiento mecánico de vigas bajo cross-bracing [10]. Las arquitecturas modernas mitigan este costo mediante aproximaciones analíticas avanzadas:

- **XGBoost (Block Processing):** Reduce el costo de ordenamiento mediante el almacenamiento estructurado en bloques de memoria pre-ordenados y optimizados para hilos paralelos. Esto reduce la complejidad temporal de la búsqueda de divisiones a un costo asintótico de $O(M \cdot K \cdot N + M \cdot d \cdot \log N)$.
- **LightGBM (Histogram-based):** Reemplaza el ordenamiento exacto continuo mapeando las variables cuantitativas dentro de B contenedores discretos e independientes (*bins*). Esto reduce drásticamente la complejidad de división de nodos a un orden de $O(M \cdot K \cdot B)$, independizando el costo computacional central de la cantidad total de instancias empíricas presentes en la base de datos original.

Por otra parte, el tiempo de inferencia (generación de predicciones operativas en producción) es altamente eficiente, requiriendo un costo temporal restringido a $O(M \cdot d)$. Esta excelente propiedad computacional hace que los ensambles basados en Gradient Boosting sean completamente viables para sistemas distribuidos en tiempo real de baja latencia.

9.4. Diagnóstico de Convergencia y Parada Temprana (*Early Stopping*)

Un componente metodológico indispensable para consolidar la precisión métrica en entornos de producción y modelado científico es el monitoreo continuo de la convergencia funcional mediante la estrategia de parada temprana o *early stopping*. Dado que el Gradient Boosting añade

árboles de forma secuencial, un número excesivo de componentes M conduce inevitablemente a la memorización del ruido estocástico del conjunto de entrenamiento, incurriendo en sobreajuste severo.

Esta optimización del comportamiento de convergencia se vuelve mandatoria cuando se trabaja bajo restricciones monótonas estrictas destinadas a forzar que las curvas de regresión científica mantengan coherencia con los principios de las ciencias físicas y biológicas [11]. Para implementar este control de forma matemática, el conjunto de datos original $\mathcal{D}$ se subdivide de manera asíncrona en un set de entrenamiento y un set de validación empírica independiente $\mathcal{D}_{\text{val}} = \{(x_j, y_j)\}_{j=1}^V$. Tras cada iteración aditiva m , se evalúa la función de pérdida agregada sobre el conjunto de validación sin actualizar los pesos nodales, tal como se modela en la Ecuación 9.13:

$$\mathcal{L}_{\text{val}}^{(m)} = \frac{1}{V} \sum_{j=1}^V L(y_j, F_{m-1}(x_j) + \eta \rho_m h_m(x_j)) \quad (9.13)$$

El criterio de parada se activa de manera formal cuando la pérdida de validación calculada no experimenta una reducción estrictamente monótona a lo largo de un horizonte prefijado de P iteraciones consecutivas (conocido como ventana de paciencia u *overfitting detector*). Este umbral de decisión se parametriza matemáticamente mediante la condición analítica descrita en la Ecuación 9.14:

$$\mathcal{L}_{\text{val}}^{(m)} \geq \min \left(\mathcal{L}_{\text{val}}^{(m-1)}, \mathcal{L}_{\text{val}}^{(m-2)}, \dots, \mathcal{L}_{\text{val}}^{(m-P)} \right) \quad (9.14)$$

La incorporación de este mecanismo reduce drásticamente el desperdicio de ciclos de cómputo en hardware de procesamiento masivo y previene de forma activa la degradación de la generalización del ensamble, aislando el modelo en su punto de máxima eficiencia estadística inter-iterativa. Esto resulta de gran ayuda en arquitecturas híbridas donde el boosting se acopla a optimizadores genéticos para etiquetar datos genómicos complejos como las secuencias unicelulares scRNA-seq [12].

9.5. Interpretabilidad y Atribución Multivariable de Características

Históricamente, los ensambles basados en boosting fueron considerados modelos de "caja negra" debido a la intrincada complejidad de rastrear miles de ramificaciones, coeficientes y pesos simultáneos en grandes conjuntos de variables longitudinales multidimensionales [13]. No obstante, la ingeniería de software predictivo contemporánea implementa dos métodos matemáticos específicos para garantizar la trazabilidad analítica de las decisiones del algoritmo.

9.5.1. Importancia de Características por Ganancia de Entropía

El primer enfoque evalúa la contribución de una variable X_k calculando la reducción neta del criterio de impureza (ya sea la varianza residual o la ganancia del Hessiano) acumulada en todos los nodos de división t donde la variable fue seleccionada a lo largo del bosque de árboles. Para un único árbol de decisión T , la importancia por ganancia se define matemáticamente en la Ecuación 9.15:

$$\mathcal{I}(X_k, T) = \sum_{t \in T} \hat{\Delta} \mathcal{L}_t \cdot \mathbb{I}(v(t) = X_k) \quad (9.15)$$

Donde $\hat{\Delta} \mathcal{L}_t$ representa la mejora en la función objetivo obtenida al dividir el nodo t , y la función indicadora $\mathbb{I}(v(t) = X_k)$ evalúa si la característica X_k fue el eje divisor en dicho nodo. Para el ensamble completo, se calcula el promedio regularizado a través de los M árboles.

9.5.2. Valores Shapley Aditivos (SHAP)

A pesar de la utilidad de la ganancia, esta métrica sufre de sesgos de consistencia si las variables están altamente correlacionadas. Para resolver esta restricción, se introducen los valores SHAP (*SHapley Additive exPlanations*), fundamentados en la teoría de juegos cooperativos. Este método distribuye la asignación del rendimiento predictivo calculando el impacto marginal de la característica X_k en todas las combinaciones posibles de subconjuntos de variables $S \subseteq F \setminus \{k\}$, siguiendo la formulación de la Ecuación 9.16:

$$\phi_i(x) = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f_x(S \cup \{i\}) - f_x(S)] \quad (9.16)$$

Donde F es el conjunto universal de características evaluadas y $f_x(S)$ representa la expectativa de la predicción del modelo condicionada a los valores del subconjunto S . De este modo, el Gradient Boosting alcanza un equilibrio óptimo entre precisión predictiva de vanguardia y transparencia explicable exigida en dominios industriales de alta responsabilidad.

9.6. Metodología y Análisis de la Literatura

A través de la extracción sistemática de datos provenientes de artículos indexados en las principales bases de datos globales, se estructuraron las dimensiones esenciales de rendimiento técnico de esta familia de algoritmos. La literatura analizada mapea un ecosistema vibrante de aplicaciones distribuidas en múltiples disciplinas empíricas. En ingeniería ambiental y minería extractiva, implementaciones eficientes basadas en LightGBM permiten predecir e interpretar los asentamientos del terreno debidos a subsidencia de carbón [14]. Por su parte, la industria petroquímica emplea variantes optimizadas mediante metaheurísticas evolutivas para estimar la tensión interfacial entre petróleo y nitrógeno bajo condiciones extremas de yacimiento [15].

En el manejo de recursos hídricos, el algoritmo se consolida como la herramienta de referencia para proyectar los índices de calidad del agua subterránea en zonas agrícolas bajo riesgo de contaminación por irrigación tecnificada [16]. Adicionalmente, el dominio de la investigación clínica aprovecha la solidez de los árboles de decisión secuenciales para estructurar modelos de analítica predictiva en medicina interna, cardiología y cuidados críticos de alta sensibilidad [17].

Finalmente, en la ciencia de los materiales e infraestructura civil se documentan aproximaciones híbridas acopladas con optimización bayesiana para determinar la resistencia a la compresión en hormigones reciclados autocompactantes [18]. Este rendimiento analítico robustece los esquemas distribuidos de aprendizaje incremental dedicados a mitigar los riesgos de rupturas en cadenas de suministro globales [19], así como las plataformas de bioinformática molecular avanzada dedicadas a inferir interacciones ligando-receptor mediante combinaciones de boosting e histogramas discretos [20].

La sistematización analítica de estos hallazgos operacionales permitió estructurar y refinar las dimensiones de rendimiento técnico explicadas en detalle en la Tabla 9.1.

9.6.1. Análisis de Sensibilidad de Hiperparámetros

Para comprender el comportamiento del algoritmo y su propensión al sobreajuste, la Tabla 9.2 detalla el impacto analítico, los rangos operacionales típicos y las estrategias de control metodológico asociadas a los hiperparámetros críticos del Gradient Boosting.

9.6.2. Estrategia de Optimización Fina de Hiperparámetros

El proceso de sintonización de hiperparámetros se realiza mediante metodologías automatizadas para asegurar la reproducibilidad. La Tabla 9.3 expone la estrategia analítica y las fronteras

Tabla 9.1: Dimensiones de análisis en algoritmos de Gradient Boosting.

Dimensión	Atributos Técnicos	Hallazgos en la Literatura
Cómputo	Velocidad nominal de entrenamiento, paralelización multihilo, aceleración nativa por GPU, escalabilidad lineal.	Las implementaciones distribuidas optimizan el procesamiento secuencial reduciendo los tiempos de cómputo en grandes datasets [2].
Memoria	Tasa de consumo de RAM, algoritmos de discretización basados en histogramas, compresión de estructuras nodales.	El uso de la técnica de binning por histogramas (HGB) reduce drásticamente las demandas de RAM en problemas moleculares complejos [20].
Complejidad	Profundidad máxima del árbol, regularización estructural, NP-Hard, tasa de aprendizaje adaptativa.	Lograr una precisión óptima requiere equilibrar la tasa de atenuación con la complejidad estructural de los nodos [1, 4].
Explicabilidad	Trazabilidad matemática de los nodos, métodos de atribución agnósticos, análisis SHAP y LIME.	La integración nativa de técnicas de Inteligencia Artificial Explicable (XAI) descompone con transparencia la importancia de variables en ciberseguridad [7].
Robustez	Codificación de variables de alta cardinalidad, imputación de valores faltantes, restricciones monótonas.	El ajuste de efectos mixtos y restricciones monótonas proporciona alta estabilidad ante ruido y dispersión extrema [9, 11].

de búsqueda numérica utilizadas comúnmente en esquemas automatizados de Optimización Bayesiana basada en Procesos Gaussianos.

9.6.3. Métricas Estadísticas de Medición de la Precisión

El éxito operacional del Gradient Boosting se cuantifica a través de métricas matemáticas que evalúan la calidad de la convergencia y la capacidad de generalización ante datos no observados durante el entrenamiento. La Tabla 9.4 detalla las formulaciones analíticas de las métricas de mayor adopción en los estudios indexados.

9.6.4. Comparativa de Infraestructura de Software y Requisitos de Hardware

Las variantes modernas de Gradient Boosting difieren en su diseño de ingeniería de software e infraestructura computacional. La Tabla 9.5 presenta una disección técnica de las plataformas líderes utilizadas para procesar la literatura analizada.

Para entornos de producción, simulación masiva y entrenamiento distribuido a gran escala de datos tabulares complejos bajo optimización bayesiana e híbrida [18], la Tabla 9.6 define el aprovisionamiento de recursos computacionales mínimos recomendados por la industria de ingeniería de software para asegurar una baja latencia operacional.

9.7. Conclusión del Capítulo

En conclusión, el análisis sistemático desarrollado a lo largo del presente capítulo demuestra de manera concluyente que la metodología de Gradient Boosting constituye una de las herramientas de software supervisado con mayor capacidad para optimizar la precisión predictiva en entornos tabulares complejos. A través del cálculo aditivo secuencial de pseudo-residuales

Tabla 9.2: Impacto operacional y control de hiperparámetros críticos.

Hiperparámetro	Rango Típico	Efecto en la Precisión y el Control del Error
Tasa de Aprendizaje (η)	0,01 – 0,3	Controla la velocidad de convergencia del ensamble. Valores bajos requieren un mayor número de árboles (M), pero garantizan una minimización estable [1].
Número de Árboles (M)	100 – 5000	Define la capacidad aditiva global. Un valor excesivo provoca sobreajuste y memorización si no está balanceado mediante parada temprana [6].
Profundidad Máxima (d)	3 – 9	Gobierna el nivel de interacción no lineal capturado por cada aprendiz débil. Profundidades elevadas aumentan exponencialmente el costo computacional [4].
Regularización (λ, α)	0 – 10	Penalizaciones $L2$ (λ) y $L1$ (α) sobre los pesos de las hojas. Indispensables en XGBoost para forzar la generalización estructural del modelo [4].

Tabla 9.3: Fronteras de sintonización analítica optimizada mediante procesos gaussianos.

Parámetro de Control	Límite Inferior	Límite Superior	Tipo de Distribución
Tasa de Aprendizaje (η)	0,001	0,5	Logarítmica Continua [1]
Submuestreo de Filas (<i>subsample</i>)	0,5	1,0	Uniforme Continua [6]
Muestreo por Columna (<i>colsample_bytree</i>)	0,4	1,0	Uniforme Continua [4]
Peso Mínimo en Nodo Hoja	1	20	Lineal Entera Discreta [1]

fundamentados en el descenso de gradiente funcional, la técnica minimiza de forma coordinada el sesgo y la varianza del sistema. Los veinte estudios indexados proporcionados convalidan su robustez matemática y escalabilidad industrial, consolidándola como una arquitectura transversal idónea para resolver retos complejos que abarcan desde la optimización del transporte, la ciberseguridad y la analítica deportiva, hasta el modelado avanzado de fenómenos mecánicos, geológicos, biológicos y biomédicos de alta sensibilidad.

Tabla 9.4: Métricas analíticas de cuantificación del rendimiento predictivo.

Métrica de Rendimiento	Formulación Matemática	Propósito en el Análisis de Gradient Boosting
Error Cuadrático Medio (MSE)	$\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$	Evalúa la magnitud del error penalizando de forma cuadrática las desviaciones macroscópicas y los <i>outliers</i> continuos [6].
Coefficiente de Determinación (R^2)	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$	Mide la proporción de la varianza total de la variable objetivo explicada de forma óptima por el modelo aditivo [1].
Tasa de Precisión de Clasificación	$\frac{TP+TN}{TP+TN+FP+FN}$	Evalúa la exactitud global del clasificador ante amenazas digitales, malware e interacciones binarias [7].

Tabla 9.5: Disección técnica de las implementaciones oficiales de Gradient Boosting.

Algoritmo	Lenguaje Base	Mecanismo de Optimización Core
XGBoost	C++ / Python	Expansión de Taylor de segundo orden, regularización implícita en la función objetivo y bloques de memoria pre-ordenados [4].
LightGBM	C++	Crecimiento de árboles orientado por hojas (<i>leaf-wise</i>), muestreo unilateral (GOSS) y agrupamiento por histogramas [14].
CatBoost	C++ / Python	Mecanismo simétrico de árboles de decisión, <i>Ordered Boosting</i> anti-sesgos y codificación dinámica de categorías [4].

Tabla 9.6: Requisitos de infraestructura computacional para entrenamiento a gran escala.

Escala del Dataset	Cores CPU Mínimos	Memoria Mínima	RAM	Soporte de Aceleración Dedicada
Pequeño ($< 10^5$ filas)	4 Cores Físicos	8 GB RAM		Opcional (CPU Execution Mode Core)
Medio ($10^5 - 10^7$ filas)	16 Cores Físicos	32 GB RAM		Recomendado (CUDA Compute Single-GPU)
Masivo ($> 10^7$ filas)	64 Cores Distribuidos	128 GB RAM		Obligatorio (Multi-GPU Tensor Cores Active)

Referencias

- [1] C. Bentéjac, A. Csörgő, and G. Martínez-Muñoz, “A comparative analysis of gradient boosting algorithms,” *Artificial Intelligence Review*, vol. 54, no. 3, pp. 1937–1967, 2021.
- [2] N. Aziz, J. Jaafar, E. A. P. Akhir, M. H. Hasan, and I. A. Aziz, “A study on gradient boosting algorithms for development of AI monitoring and prediction systems,” in *Proceedings of Universiti Teknologi PETRONAS Research Conference*, oct 2020.
- [3] Y. Zhang and A. Haghani, “A gradient boosting method to improve travel time prediction,” *Transportation Research Part C: Emerging Technologies*, vol. 58, pp. 308–324, 2015.
- [4] B. Kumar and T. Kumar, “Comparative analysis of ML based gradient boosting algorithms: XGBoost, CatBoost, and LightGBM,” *Journal of Scientific and Engineering Research*, vol. 7, no. 8, pp. 235–239, 2020.
- [5] H. Min and R. Ji, “Construction of the prediction model and analysis of key winning factors in world women’s volleyball using gradient boosting decision tree,” *Scientific Reports*, vol. 15, p. 10245, oct 2025.
- [6] L. W. Rizkallah, “Enhancing the performance of gradient boosting trees on regression problems,” *Journal of Big Data*, vol. 12, feb 2025.
- [7] M. Elattar, A. Younes, I. Gad, and I. Elkabani, “Explainable AI model for PDFMal detection based on gradient boosting model,” *Neural Computing and Applications*, vol. 36, pp. 21607–21622, sep 2024.
- [8] D. Chevalier and M.-P. Côté, “From point to probabilistic gradient boosting for claim frequency and severity prediction,” *North American Actuarial Journal*, pp. 1–44, 2024.
- [9] L. Knieper, T. Hothorn, E. Bergherr, and C. Griesbach, “Gradient boosting for generalised additive mixed models,” *Statistics and Computing*, vol. 35, no. 84, 2025.
- [10] N. Dahiya, B. Saini, and H. D. Chalak, “Gradient boosting-based regression modelling for estimating the time period of the irregular precast concrete structural system with cross bracing,” *Journal of King Saud University – Engineering Sciences*, vol. 37, dic 2025.
- [11] A. Hevathige, “Learning monotonic constraints for scientific regression: A statistical gradient boosting framework,” *Journal of King Saud University - Computer and Information Sciences*, may 2026.
- [12] O. Elnahas, W. M. Ead, Y. Qiu, and J. Lu, “Ensemble machine learning-based pre-trained annotation approach for scRNA-seq data using gradient boosting with genetic optimizer,” *BMC Bioinformatics*, vol. 26, jul 2025.
- [13] O. R. Olaniran, S. F. Olaniran, J. Allohibi, A. A. Alharbi, and N. M. Alharbi, “Mixed effect gradient boosting for high-dimensional longitudinal data,” *Scientific Reports*, ago 2025.

- [14] X. Cui, S. Yang, and J. Wang, “Performance evaluation and interpretation of hybrid models based on light gradient boosting machine to predict coal mining subsidence,” *Scientific Reports*, vol. 14, no. 1, pp. 2456–2468, 2024.
- [15] M. Abushuhel, H. Mohammad, R. Rao P. S., *et al.*, “Pioneering oil and nitrogen interfacial tension using evolutionarily optimized gradient boosting machine,” *Scientific Reports*, mar 2026.
- [16] I. Akhtar, M. Ashraf, Y. Niaz, *et al.*, “Prediction of groundwater quality in irrigated areas using a novel gradient boosting approach,” *Applied Water Science*, vol. 16, feb 2026.
- [17] Z. Zhang, Y. Zhao, A. Canes, D. Steinberg, and O. Lyshevska, “Predictive analytics with gradient boosting in clinical medicine,” *Annals of Translational Medicine*, vol. 7, p. 152, abr 2019.
- [18] K. C. Onyelowe, Z. A. Tariq, H. Ikara, *et al.*, “Self compacting concrete with recycled aggregate compressive strength prediction based on gradient boosting regression tree with bayesian optimization hybrid model,” *Scientific Reports*, ago 2025.
- [19] A. Kafou, A. Alzubi, and T. Oz, “Supply chain risk prediction using elite attentive foraging optimized incremental distributed learning based deep gradient boosting model,” *Discover Computing*, vol. 28, jun 2025.
- [20] L. Zhou, J. Song, Z. Li, Y. Hu, and W. Guo, “THGB: predicting ligand-receptor interactions by combining tree boosting and histogram-based gradient boosting,” *Scientific Reports*, vol. 14, nov 2024.